Ficha de preprocesamiento

1. Identificación del dataset.

El artículo seleccionado corresponde a Rahaman MM, Sadique A, Alam J, Khan F, et al. (2025), Draft genome sequence of Pseudomonas aeruginosa strain maqsudiensis isolated from cattle swab in Dhaka, Bangladesh, publicado en Microbiology Resource Announcements, 14(6): e01190-24 (DOI: 10.1128/mra.01190-24). El organismo estudiado es Pseudomonas aeruginosa strain maqsudiensis, aislado de hisopados rectales de ganado en el Gabtoli Cattle Market, Dhaka, Bangladesh, el 13 de septiembre de 2021. Los datos están registrados bajo el BioProject PRJNA1179666, BioSample SAMN44500193 y run SRR31155591. Según el paper, la secuenciación se realizó en Illumina MiSeq, mediante un diseño paired-end de 2 × 150 pb. Se informan 637.121 paired-end reads,en la descarga se observaron 637.121 *spots* y 1.274.242 lecturas, es decir, 637.121 pares . Para el análisis, se descargó mediante prefetch y fasterq-dump, y se realizó un submuestreo de 300.000 pares de lecturas con seqkit sample -s 11 -n 300000, utilizando la misma semilla para R1 y R2. Mediante seqkit stats -a se observaron 300.000 lecturas en cada archivo, con longitudes entre 35 y 151 pb (nominal: 150 pb) y promedios de 147,3 pb en R1 y 147,4 pb en R2. La variabilidad de longitud en las lecturas crudas sugiere un posible recorte previo a su depósito en SRA, aunque el artículo no lo menciona. Finalmente, la codificación de calidad se identificó mediante la inspección de los caracteres de las líneas FASTQ con zcat, awk, head, fold y sort. Se obtuvo un rango desde (Q2) hasta I (Q40), incluyendo caracteres inferiores al ASCII 59, lo que permitió descartar Phred+64 y confirmar el uso de Phred+33 (Sanger / Illumina 1.8+).

2. Tabla antes y después del recorte.

Archivo	Lecturas	% retenido	Largo promedio (pb)	% bases >= Q30	Adaptador detectado (FastQC)	Secuencias sobrerrepresentadas
R1 crudo	300.000	100%	147.3	90.40%	No detectado	1 secuencia de 35 N (WARN)
R2 crudo	300.000	100%	147.4	75.95%	No detectado	1 secuencia de 35 N (WARN)
R1 recortado	194.686	64.90%	147.5	96.72%	No detectado	Ninguna
R2 recortado	194.686	64.90%	147.4	89.49%	No detectado	Ninguna

3. Decisiones de recorte.

Respecto a los parámetros, --average_qual 30 se basó en el paper, que señala: “reads were trimmed using Trimmomatic v0.39 (AVGQUAL 30)”, utilizando su equivalente en fastp para mantener una calidad promedio mínima de Q30. Por otra parte, --detect_adapter_for_pe se incorporó considerando que el artículo menciona la eliminación de adaptadores, aunque sin especificar cuáles; se utilizó detección automática como medida preventiva. Los parámetros

--length_required 50 y --n_base_limit 5 fueron decisiones propias: el primero permite eliminar lecturas menores a 50 pb, considerando que inicialmente existían lecturas de hasta 35 pb, mientras que el segundo mantiene el límite de bases ambiguas en el valor predeterminado de fastp. Además, se mantuvieron los filtros de calidad por base que aplica la herramienta por defecto (-q 15 -u 40).

El recorte permitió descartar 210.628 de las 600.000 lecturas, principalmente por baja calidad (208.758) y, en menor medida, por longitud inferior a 50 pb (1.870). No se eliminaron lecturas por exceso de bases N. Se observó una mejora en la calidad: las bases ≥Q30 aumentaron de 90,40% a 96,72% en R1 y de 75,95% a 89,49% en R2. Asimismo, el módulo Overrepresented sequences pasó de WARN a PASS, debido a la eliminación de secuencias con numerosas bases ambiguas. La mayor pérdida de lecturas se relaciona con la calidad inicial más baja de R2, lo que es habitual en secuenciación paired-end, donde la lectura reversa suele presentar mayor degradación.

Después del recorte, algunos módulos de FastQC continuaron en alerta. Per base sequence content y Per sequence GC content permanecieron en FAIL, debido principalmente al alto contenido GC propio de Pseudomonas aeruginosa: las lecturas presentan valores de 65,8% y 66,0%, cercanos al 66,44% informado para el ensamblado en el paper. Por tanto, estas alertas responden a la composición del genoma bacteriano y no necesariamente a problemas de calidad. Por su parte, Sequence length distribution permaneció en WARN porque las lecturas conservan longitudes variables, aunque cerca del 94% de R1 se concentra entre 145 y 151 pb. Finalmente, Sequence duplication levels se mantuvo en PASS, con valores aproximados de 5–7% antes y 8% después del recorte. Este leve aumento puede explicarse por la eliminación de lecturas únicas de baja calidad, haciendo relativamente más frecuentes las secuencias repetidas restantes.

4. ¿Se puede reproducir el paper?.

La información entregada en los Métodos es parcialmente suficiente, ya que permite identificar y descargar los datos de secuenciación mediante el SRR, además de conocer la plataforma, el diseño de lectura y las versiones de FastQC (v0.11.9) y Trimmomatic (v0.39), junto con el umbral de calidad AVGQUAL 30. Sin embargo, faltan detalles importantes para reproducir el procesamiento, como el modo de recorte (paired-end o single-end), el archivo de adaptadores utilizado (ILLUMINACLIP), la longitud mínima de lectura y otros parámetros aplicados. Tampoco se aclara si las 464.433 lecturas de alta calidad finales corresponden a pares o lecturas individuales, ni si los datos depositados en SRA ya habían sido recortados previamente. En nuestro análisis se obtuvo una retención del 64,9% (194.686 de 300.000 pares), frente al aproximadamente 72,9% informado por el paper (464.433 de 637.121, si ambas cifras corresponden a pares). Como solo 1.870 lecturas cayeron por largo y ninguna por bases N, esta diferencia se atribuye principalmente al uso de otra herramienta, con criterios de calidad y de conteo distintos: fastp aplica además filtros por defecto que el paper no menciona (-q 15 -u 40) y elimina ambas lecturas de un par cuando una falla, mientras que Trimmomatic en modo paired-end puede conservar la lectura sobreviviente como no pareada. Esto último no está confirmado. Finalmente, al ejecutar nuevamente run_qc.sh desde cero en un clon limpio del repositorio en Leftraru, incluyendo la descarga, el submuestreo con semilla fija, el control de calidad y el recorte, se obtuvieron los mismos conteos y porcentajes, respaldando la reproducibilidad de nuestro procedimiento. Para facilitar la reproducción del análisis por otros grupos, agregaríamos a los Métodos la

siguiente información: “Reads were trimmed with Trimmomatic v0.39 in paired-end mode (ILLUMINACLIP:[adapter file]:2:30:10, AVGQUAL:30, MINLEN:[value]), retaining 464,433 read pairs out of 637,121 sequenced.”

Repositorio: https://github.com/Alvaritopalas/proyecto-qc
Commit entregado: `b4aa045` (código, entorno y reportes; la ficha en PDF se agregó en un commit posterior)